

Análise Exploratória de Dados

IMDB Top 1000 Movies & TV Shows

Tarefa 2 — Visualização de Dados

Autor	Tiago Neto
Nº	54172
Curso	Inteligência Artificial e Ciência de Dados
UC	Visualização de Dados
Dataset	IMDB Top 1000 Movies and TV Shows (Kaggle)
Ano	2024/25

1. Qualidade dos Dados

O dataset apresenta quatro classes de problemas que exigem tratamento antes de qualquer análise.

Coluna	Problema	Ação
Released_Year	"PG" em vez de ano (scraping error)	Drop 1 linha via <code>to_numeric(errors='coerce')</code>
Runtime	String '142 min' — não é inteiro	Strip ' min' → cast <code>Int64</code>
Gross	String '\$28,341,469' com \$ e vírgulas	Strip símbolos → cast <code>Float64</code> (NaN mantidos)
Certificate	Mix de sistemas EUA + Índia + 101 NaN	Flag emitido; NaN mantidos
Encoding	Caracteres latin-1 (ex: León)	<code>pd.read_csv(..., encoding='latin-1')</code>

Encoding & scraping error

```
df = pd.read_csv(f, encoding="latin-1")
df["Year"] =
pd.to_numeric(df["Released_Year"],
errors="coerce") # "PG" → NaN
df = df[df["Year"].notna()]
```

Runtime & Gross cleanup

```
df["Runtime_min"] = (
df["Runtime"].str.replace(" min", "")
.astype("Int64"))
df["Gross_num"] = (
df["Gross"].str.replace("$,","", regex=True)
.astype("Float64"))
```


Valores Ausentes

Coluna	Ausentes	%	Decisão
Gross	169	16.9%	Mantidos — não imputar receitas
Meta_score	157	15.7%	Mantidos — análise opcional
Certificate	101	10.1%	Mantidos + flag sistema misto

Sem duplicados exactos. 'Drishyam' aparece duas vezes mas são produções independentes — ambas mantidas.

2. Visualizações Corretas


C1 — Distribuição de Rating por Género



Cada ponto = 1 filme · linha branca = mediana · eixo Y começa no mínimo real (7.4)

Leitura: Drama tem a maior base (~330 filmes) e maior variância. Crime concentra-se acima da mediana — só os mais fortes entram no Top 1000. Animation tem a distribuição mais compacta, refletindo qualidade de produção uniforme.

C2 — Filmes do Top 1000 por Década




Eixo Y começa em 0 · contagens anotadas em cada barra · sem manipulação de escala

Leitura: Os anos 2000–2010 representam ~48% do dataset. Este enviesamento de recência reflete que mais utilizadores votam em filmes recentes — o Top 1000 mede popularidade atual, não valor cinematográfico absoluto.

3. Visualizações Enganosas

Os gráficos seguintes usam dados reais mas aplicam técnicas documentadas de manipulação visual. Os mecanismos de engano estão explicitados abaixo de cada figura.


E1 — Revenue Médio por Género



Revenue médio por género primário. Nota: o eixo Y não começa em zero.

#	Mecanismo	Impacto
1	Eixo Y truncado	Diferença Family/Crime parece 10× — real é ~6.5×
2	Média em vez de mediana	Um blockbuster (\$1.5B) infla toda a categoria Action
3	169 filmes sem Gross excluídos	Exclusão silenciosa cria selection bias não declarado
4	Sem normalização de orçamento	Action/Family custam 5–10× mais — ROI pode ser inferior

E2 — Duração Mediana por Década (cherry-picking temporal)



Esquerda: série completa (1960–2020). Direita: intervalo cherry-picked (1980–2019).

Mecanismo: O painel da direita seleciona 4 décadas (1980–2019) que formam uma linha crescente, sugerindo 'os filmes são cada vez mais longos'. O painel da esquerda mostra que a duração caiu nos anos 1980 e oscilou — não existe tendência monotónica. A escala é idêntica; a única diferença é a escolha do intervalo, não declarada no título.

4. Conclusão

A qualidade de uma análise começa antes de qualquer gráfico. O dataset contém erros reais — encoding incorreto, scraping errors, tipos semânticos errados, missing data — que, se ignorados, invalidam os resultados mesmo com código tecnicamente funcional. As visualizações enganosas (E1 e E2) demonstram que os mesmos dados podem contar histórias opostas conforme as decisões de apresentação. Uma visualização não é nunca neutra.

Ficheiros entregues: imdb_analysis.py · imdb_viz.py · requirements.txt · este relatório